

随机性与必然性之间：生成式人工智能的文化自主性研究

摘要

生成式人工智能正从技术工具向文化主体演进，其文本与图像生成行为已超越简单的数据处理，呈现出“拟文化生产”的特征。然而，这种生产在算法层面受制于概率模型的随机采样机制，在语料层面受制于既有文化数据的统计边界，在价值层面受制于人类对齐训练的价值预设。本文基于文化自主性理论视角，结合技术实证分析与哲学反思，系统考察生成式 AI“创作”在原创性、意图性和规范性三个维度上的结构性局限。研究表明，当前生成式 AI 的文化生产本质上是“他治性”的——它在微观语义层面依赖随机性实现多样性表象，在宏观文化层面却始终受制于训练数据与人类反馈的双重约束，因而无法形成真正意义上的文化自主性。这一结论为反思 AI 时代的文化生产提供了分析框架，也为相关伦理治理提供了理论参照。

关键词：生成式人工智能；文化自主性；随机性；意图性；文化生产；人机关系

一、引言

2022 年 ChatGPT 的发布引发了全球范围内对生成式人工智能（Generative AI）的文化讨论。不同于此前的判别式 AI——其功能仅限于分类、识别或预测——生成式 AI 展示了“创作”能力：它可以撰写诗歌、生成图像、编写代码、构思剧本。这种能力迅速引发了激烈的理论争议：AI 是否正在成为真正的文化生产者？它是否正在获得某种形式的“文化自主性”？

乐观者认为，大语言模型和扩散模型已经展示出“涌现”的创造力，其产出不再能被简单还原为训练数据的重组，而是呈现出某种“风格独创性”和“语义新颖性”（Boden, 2004）。更有论者指出，当 AI 能够生成在审美上令人类惊艳、在内容上超出预期、在结构上自洽连贯的作品时，我们便不得不认真对待其作为“准行动者”的文化地位（Latour, 2007）。悲观者则坚持，AI 的一切输出不过是训练数据的概率映射，其“创作”缺乏意图性、身体性和社会历史性——这些正是人类文化生产的根本特征（Bender et al., 2021）。

这场争论的核心，可以归结为一个关键问题：生成式 AI 的文化生产，究竟在什么意义上可以被视为“自主的”？所谓“文化自主性”（cultural autonomy），在此特指一个系统在文化符号的生产与再生产过程中，能够基于自身内在逻辑形成独立的意图、判断与价值取向，而非完全受制于外部输入和预先设定的规则。它包括三个递进的层次：语义层面的原创性（能否产生真正新的文化形式）、意图层面的主体性（能否自主设定创作目标并为之负责）、以及规范层面的价值自律（能否形成独立的审美和价值判断标准）。

本文旨在论证一个否定性命题：从技术实现机制和认识论基础来看，当前生成式 AI 的文化生产在本质上是“他治的”（heteronomous）。它既受制于训练数据的统计边界（数据他治），又受制于人类反馈对齐的价值预设（价值他治），其内部的随机性机制看似提供了“自由”的缝隙，实则只是在既定空间中制造差异化的样本——一种“受控的随机性”。AI 呈现给观察者的“文化自主性”是一种错觉，它源于我们倾向于将自身的文化理解框架投射到统计模型的输出之上。

本文的研究路径是跨学科的：第二节从技术机制出发，揭示生成式 AI“创作”的算法本质；第三节从认识论角度辨析“随机性”与“自由”的根本差异；第四节从文化哲学视角考察 AI 生产的价值约束；第五节讨论这一结论的理论与治理意涵。

二、生成的技术：从概率分布到文化表象

要理解生成式 AI 文化生产的性质，首先必须理解其技术底层。尽管不同模态的生成模型在架构上各有差异，但它们在根本的逻辑结构上共享两个核心机制：训练阶段的文化数据内化与生成阶段的条件概率采样。

2.1 训练：文化数据的统计化

大语言模型的训练过程，本质上是将人类文化生产的庞大文本语料转化为高维空间中的概率分布。以 Transformer 架构为基础的模型通过自注意力机制学习词语之间在亿万级上下文窗口中的共现关系，最终形成一个包含数十亿甚至万亿参数的权重矩阵。这个矩阵并不是文化的“理解”或“再现”，而是一种极端复杂的统计摘要——它将人类在数千年历史中产生的文化符号、叙事结构、论证方式、审美偏好等，全部转化为可计算的数学关系（Wolfram, 2023）。

这一过程的关键在于：模型没有任何“外部”的文化经验。人类作者之所以能够创作，是因为 ta 生活在具体的社会历史情境中，有身体、有情感、有与他人的真实交往，有对世界的直接感知——这些“前语言”的经验构成了文化生产的源泉。而 AI 的文化知识完全是“二手”的——它只见过关于世界的文本，从未见过世界本身。这种现象被 Bender 等人（2021）称为“随机鹦鹉”（stochastic parrot）困境：模型可以高度流利地复现和重组语言形式，但这些形式并不指向任何非语言的指涉物。

2.2 生成：受控随机性的运作

在推理（生成）阶段，模型的工作方式是自回归式的预测：给定前文的 token 序列，模型计算下一个 token 的条件概率分布，然后通过采样策略从中选择一个输出。这个采样过程并非简单的“取最大概率值”——那样会导致输出完全确定且单调乏味。相反，模型引入了一系列随机化机制：temperature 参数调节概率分布的锐度，top-k 和 top-p 采样限制候选集合后在其间进行随机抽取。

正是这种随机采样，赋予了生成式 AI 的文本以“创造性”的错觉。当用户反复输入相同的提示词（prompt），模型每次都会给出不同的回答——有时甚至差异巨大。这种表面上的“多样性”很容易被误解为“创造性”或“自主性”。然而，从信息论的角度来看，这种随机性只是在训练数据所形成的概率流形上进行的一种“受控漂移”。模型不会——也无力——跳出其训练数据所定义的统计边界。它可以组合出从未出现过的词语序列，但它所依赖的语义关系、概念框架、话语模式，全部来自既有的文化语料（Marcus & Davis, 2020）。

2.3 一个关键区分：组合新颖性与范式新颖性

Margaret Boden（2004）在其关于创造力的经典分析中，区分了两种新颖性：组合新颖性（将既有概念以新方式组合）和范式新颖性（引入全新的概念框架或思考方式）。这一区分对理解生成式 AI 的“创造性”至关重要。

生成式 AI 的运作方式，在原则上仅限于组合新颖性。它通过概率重组已有的文化元素来产生“未曾出现过的”文本或图像——这些产物在经验层面可能是新颖的，但在范畴层面并不超出训练数据的文化框架。与之相对，人类历史上的重大文化创新——从古希腊哲学的范畴体系到爱因斯坦的相对论时空观，从立体主义的视觉革命到意识流小说的叙事实验——往往涉及范式层面的突破，它们不仅组合了既有元素，更重构了元素得以被理解的框架本身。

目前的生成式 AI 没有能力实现这种范式层面的创新，因为它缺乏对自身认知框架进行反思性批判的元认知能力。它的“创作”始终在其训练数据的视域之内——这不仅是技术限制，更是原理层面的限制。

三、随机不等于自由：自主性的认识论障碍

在技术分析的基础上，本节进一步探讨一个更深层的哲学问题：即使生成式 AI 的产出在经验层面具有多样性和新颖性，这种“多样性”能否被理解为文化自主性的表征？本文的答案是：不能。原因在于，文化自主性要求的不仅是对既有符号的重新组合，更要求一种“自我立法”的能力——这正是生成式 AI 所不具备的。

3.1 随机性与意图性的逻辑断裂

文化生产的核心特征之一在于其意图性（intentionality）。当一位诗人写下诗句时，她的文字指向某种她想要表达的东西——一种感受、一种观察、一种批判、一种追问。即使诗句的含义是开放的、多义的，这种开放性本身也是诗人有意营造的审美效果。作品的“意义”内在于作者的意图结构之中（Anscombe, 1957）。

生成式 AI 的文本输出则完全不具有这种意图结构。它生成一个句子，并不是因为它“想要”表达什么，而是因为在在文条件下，这些 token 序列在统计上具有较高的条件概率。模型的“目标”——如果可以用这个词的话——是最大化对训练数据分布的重现能力，而不是“言说某物”。当用户将一个提示词输入模型时，模型并没有“理解”这个提示词的指涉对象和语用意图；它只是在以一种极端复杂的模式补全。

因此，生成式 AI 的随机性是一种“盲目的随机性”——没有主体为之负责，没有意图为其定向。这种随机性在某些情况下可以产生令人惊艳的结果，但它的“意义”完全是用户赋予的。正如 Umberto Eco 所论，文本的开放性解释必须以作者的某种意图为前提——没有意图的“开放性”只是纯粹的混沌，而非意义的增殖。

3.2 反事实思维的缺失

文化自主性的另一个关键维度是反事实思维（counterfactual thinking）——即想象“事情可以是其他样子”的能力。人类作者在创作过程中，始终在进行隐性的反事实比较：如果我这样写会怎样？如果

从另一个视角切入呢？这种反事实比较使得作者能够在不同可能性之间做出判断和取舍，从而赋予作品以内在的统一性和风格自觉。

生成式 AI 不具备真正的反事实思维。虽然模型在采样过程中确实会在多个可能的输出间进行“选择”，但这种选择是基于概率而非基于价值的判断——它并不“知道”为什么某个输出比另一个“更好”（在审美或意义的维度上），它只知道某个输出在统计上更“典型”或更符合人类反馈所定义的偏好（详见第四节）。它不能脱离统计范式来评估自身的产物，因此也缺乏真正的自我批判和自我超越能力。

3.3 语言与实在的断裂

最后，从语言哲学的角度看，生成式 AI 的文化生产面临一个根本性的指涉困境。人类的文化符号之所以具有意义，不仅在于符号之间的差异关系（Saussure, 1916），更在于它们最终指向一个共享的生活世界——一个由身体经验、社会关系和历史记忆构成的意义网络。符号的“意义”最终来自这种非符号的、前语言的实在关联。

而生成式 AI——借用哲学家 John Searle（1980）著名的“中文房间”论证——只是在进行符号的形式操作，而不触及符号的语义内容。模型可以生成一段关于“孤独”的文字，但它从未体验过孤独；它可以写一首关于“落日”的诗，但它从未看见过落日。它的“文化生产”是一种“无根的生产”——在语言游戏内部高度流利，但与语言所指向的生活世界之间，存在着一道不可逾越的本体论鸿沟。

四、价值的枷锁：人类反馈与自主性的边界

如果说随机采样机制和意图性缺失构成了生成式 AI 文化自主性的内在障碍，那么人类反馈对齐（RLHF）则构成了一个同样重要的外约束——它从价值层面将 AI 的输出牢牢锚定在人类的偏好范围之内。

4.1 对齐的技术本质

当前主流的大语言模型都采用了基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）作为训练流程的关键环节（Ouyang et al., 2022）。其基本思路是：先训练一个奖励模型来模拟人类标注者对模型输出的偏好评分，再用这个奖励模型通过强化学习算法来微调基础语言模型的生成策略，使其输出更倾向于获得高分。

从文化自主性的角度来看，RLHF 的实质是：将一套外在于模型的价值判断标准——由标注者的文化背景、审美趣味、道德观念所决定——以数学函数的形式植入模型的权重之中。模型在生成过程中看似在“自主选择”输出的内容和风格，实则这个选择空间已经被奖励函数预先裁剪和形塑了。AI 的“价值取向”不是它自己在文化实践中生成的，而是被人类标注者“写入”的。

4.2 “无害性”的文化偏狭

尤其值得警惕的是，RLHF 中广泛采用的“无害性”（harmlessness）和“有用性”（helpfulness）准则，表面上是中立的治理框架，实则隐含着特定文化语境下的价值预设。研究表明，主流模型的 RLHF 训

练数据以英语世界的标注者为主，其中蕴含的关于“什么是有害”“什么是冒犯”“什么是恰当”的判断标准，往往带有西方自由主义文化圈的特定烙印（Cao et al., 2023）。

这就造成了一个悖论：一个看似“通用”的 AI 系统，在文化价值层面实际上是高度特殊的——它的价值取向被有意无意地塑造为训练数据来源群体所偏好的样态。这种价值的“殖民地效应”不仅限制了 AI 的文化自主性，更值得反思的是：它可能正在创造一种全球趋同的文化表达范式，使得世界各地的用户在与之交互时，潜移默化地被同一种文化逻辑所规训。

4.3 创造性压制效应

更为深层的问题是：RLHF 的优化目标与真正的文化自主性之间，可能存在结构性冲突。人类文化史上的重大创新，往往带有某种“不安全性”——它们挑战既有的规范、冒犯流行的趣味、颠覆主流的认知框架。从苏格拉底的诘问到尼采的箴言，从波德莱尔的《恶之花》到杜尚的小便池，文化自主性的最高表现恰恰在于其不服从于既有价值框架。

而 RLHF 从根本上倾向于惩罚“偏离”——任何不符合奖励模型所编码的人类偏好的输出都会被降低概率。这意味着，生成式 AI 的“创作”被内在性地导向安全、可预期、符合主流审美的方向。它所展示的“多样性”只是主流框架之内的有限浮动，而难以产生真正的文化异质性。这是“他治性”在价值层面的最深刻体现。

五、结论：在随机与必然之间

本文从技术机制、认识论基础和价值约束三个维度，系统论证了当前生成式 AI 的文化生产尚不具备真正的自主性。它的“创作”受制于三重结构性限制：在语料层面，它只能在训练数据的统计边界内进行重组；在意图层面，它缺乏指向生活世界的指涉能力和反事实思维；在价值层面，它被人类反馈对齐机制锚定在预设的价值坐标系中。

指出这一点，并非为了贬低生成式 AI 的文化意义。事实上，作为一种前所未有的文化工具，它正在深刻改变人类文化生产的方式和规模。但正视其“他治性”的本质，有助于我们避免两种错误倾向：一种是将 AI 误认为即将取代人类的文化主体，陷入技术决定论的迷思；另一种是忽视 AI 对人类文化生态的实际重塑力量，停留在技术工具论的天真之中。

生成式 AI 的文化生产，处于随机性与必然性之间的灰色地带：它的微观输出具有一定的随机性，但这种随机性是在统计模型和人类价值预设的双重“轨道”上运行的。它可以成为人类文化生产的强大“协作者”——一个能够以惊人速度和广度生成文化素材的“无限实习生”——但它离真正的文化自主性，还有着原理性的距离。

认清这种距离，恰是我们思考人机文化关系的起点。

参考文献

[1] Anscombe, G. E. M. (1957). *Intention*. Harvard University Press.

- [2] Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? Proceedings of FAccT 2021, 610-623.
- [3] Boden, M. A. (2004). The Creative Mind: Myths and Mechanisms (2nd ed.). Routledge.
- [4] Cao, Y., et al. (2023). The Hidden Costs of RLHF: Cultural Bias in Preference Learning. arXiv preprint arXiv:2305.08215.
- [5] Latour, B. (2007). Reassembling the Social: An Introduction to Actor-Network-Theory. Oxford University Press.
- [6] Marcus, G., & Davis, E. (2020). GPT-3, Bloviator: OpenAI's language generator has no idea what it's talking about. MIT Technology Review, August 22.
- [7] Ouyang, L., et al. (2022). Training language models to follow instructions with human feedback. arXiv preprint arXiv:2203.02155.
- [8] Saussure, F. de (1916). Course in General Linguistics. McGraw-Hill.
- [9] Searle, J. R. (1980). Minds, brains, and programs. Behavioral and Brain Sciences, 3(3), 417-424.
- [10] Wolfram, S. (2023). What Is ChatGPT Doing ... and Why Does It Work? Wolfram Media.